

피임 방법 선택 예측모델 개발 및 시각화

작성자 : 한동해



1. 개요 및 현황

사업과제

AI기반 피임 방법 선택 예측모델 개발 및 시각화

추진배경 및 목적

■ 프로젝트 목적

현재 대한민국의 합계출산율은 0.63에서 0.7 수준으로 소폭 상승하였으나, 여전히 결혼 후 자녀를 갖지 않는 가구가 증가하고 있는 상황입니다. 이러한 사회 현상을 데이터 관점에서 분석하기 위해 본 프로젝트를 진행하였습니다

본 프로젝트는 개인 특성 데이터를 기반으로 피임 방법 선택 패턴을 예측하는 딥러닝 모델을 구축하는 것을 목표로 합니다. 기존 통계적 접근 방식보다 비선형 관계를 효과적으로 학습할 수 있는 딥러닝 모델을 적용하여 보다 정밀한 예측이 가능하도록 설계하였습니다.

2. 과제 범위

과제구분		내용
AI	AI기반 피임 방법 선택모델 구현	개인 특성 기반 피임 방법(미사용/단기/장기) 다중 분류 모델 설계
		범주형·수치형 변수를 고려한 Embedding 기반 딥러닝 모델 적용
		Model A/B/C 비교를 통한 성능 기반 최적 모델 선정
		Macro-F1 지표를 활용한 클래스 불균형 대응
시각화	모델 선택 및 입력정보 구현	EDA 기반 변수 분포 및 데이터 특성 시각화
		학습 과정 시각화 (Accuracy / Loss)
		혼동행렬 및 ROC Curve 기반 모델 해석 시각화
		Streamlit 기반 예측 결과 UI 시연

3. 과제 추진 방법 - 구축 대상 선정 기준

데이터 접근성 및 활용성

- Census of Married Women(CMC) 데이터를 활용
- 추가적인 조사를 통한 데이터 수집으로 모델 학습이 매우 용이

데이터셋 형식 및 특징

- 데이터 형식: ARFF (Attribute-Relation File Format)
- 데이터 유형: 정형(Tabular) 데이터
- 총 샘플 수: 1,473개
- 변수 구성: 입력 변수 9개 + 타겟 변수 1개


문제 해결 기여도

- 예측모델을 통해 출산율 문제를 데이터로 해석하는 시도
- 개인 특성 기반 피임 방법 추천 모델
- 출산·가족 관련 정책 및 교육용 데이터 분석 확장(차후 가능성)

3. 과제 추진 방법 – AI 예측 분석모델 적용 대상

데이터	데이터셋 형식 및 특징	주요 입력 변수 (Feature)	타겟 변수 (Target)
분석 기능	- ARFF (Attribute-Relation File Format) 정형(Tabular) 데이터 - 총 샘플 수: 1,473 - 변수 구성: 입력 변수 9개 + 타겟 변수 1개	- wife_age : 아내 나이 - wife_education : 아내 교육 수준 - husband_education : 남편 교육 수준 - children : 자녀 수 - wife_religion : 종교 여부 - wife_working : 직업 유무 - husband_occupation : 남편 직업군 - standard_of_living : 생활 수준 - media_exposure : 미디어 노출 여부	contraceptive_method 1 : 사용 안 함 2 : 단기 피임 방법 3 : 장기 피임 방법

3. 과제 추진 방법 - AI 예측 분석모델 구축 프로세스



4. 주요 결과물 – 데이터 수집

데이터 수집 및 전처리

- openml.org -> dataset 자료 수집
- <https://www.openml.org/search?type=data&status=active&id=23&sort=runs>

The screenshot shows the OpenML dataset page for ID 23. The dataset is titled 'Contraceptive Method Choice' and is described as a subset of the 1987 National Indonesian Contraceptive Prevalence Survey. It contains 1479 instances and 10 attributes. The attributes include age, education, husband's education, number of children, religion, working status, contraceptive use, and standard of living index. The dataset is available for download in various formats (CSV, JSON, etc.) and is licensed under the CC-BY-NC-SA license.

cmc

ID: 23 | Verified | ARFF | Public | 2014-04-06 11:15

License: CC-BY-NC-SA | Downloads: 10,000+

Demographic | Education | Family Planning | Health | OpenMLCC10 | OpenML100 | Sociology | ...

Description

Author: Tjen-Sien Lim Source: An adaptation from ICI (Please refer to the citation)

1. Title: Contraceptive Method Choice
2. Source(s) (el Origin: This dataset is a subset of the 1987 National Indonesian Contraceptive Prevalence Survey (IC) created by Tjen-Sien Lim (tjen@stat.wisc.edu) (c) Date: June 7, 1997
3. Postscript: Lim, T.S., Lim, W.Y. & Shih, Y.S. (1998) A Comparison of Prediction Accuracy, Complexity, and Training Time of Thirty-three Old and New Classification Algorithms. Machine Learning, Portland, OR: AAAI Press.
4. Relevant information: This dataset is a subset of the 1987 National Indonesian Contraceptive Prevalence Survey. The sample consists of married women who were either not pregnant or do not know if they were at the time of the survey. The problem is to predict the current contraceptive method choice (no use, long-term methods, or short-term methods) of a woman based on her demographic and socio-economic characteristics.
5. Number of Instances: 1479
6. Number of Attributes: 10 (including the class attribute)
7. Attribute Information:
 1. Wife's age (numerical)
 2. Wife's education (categorical) {below, 2, 3, 4=high}
 3. Husband's education (categorical) {below, 2, 3, 4=high}
 4. Number of children ever born (numerical)
 5. Wife's religion (binary) {0=Non-Islam, 1=Islam}
 6. Wife's now working (binary) {0=Yes, 1=No}
 7. Husband's occupation (categorical) {1, 2, 3, 4}
 8. Standard of living index (categorical) {1=low, 2, 3, 4=high}
 9. Media exposure (binary) {0=Good, 1=Not good}
 10. Contraceptive method used (class attribute) {1=No use, 2=Long-term, 3=Short-term}
8. Missing Attribute Values: None

Information about the dataset (1) ASST (ARFF) (2) ASST (JSON) (3)

4. 주요 결과물 – 데이터 수집

데이터 수집 및 전처리

- 총 변수 수 10개(입력 변수 9개 + 타겟 변수 1개)
- 결측치가 없다는 것을 확인

```
display(df.describe(include="all"))

missing = df.isna().mean().sort_values(ascending=False)
print("\n[Missing ratio]")
print(missing)

df_clean = df.dropna().copy()
print("\nClean shape:", df_clean.shape)
```

```
Raw shape: (1473, 10)
```

	wife_age	wife_edu	husband_edu	children	wife_religion	wife_working	husband_occ	living_index	media_exposure	target
0	24	2	3	3	1	1	2	3	0	1
1	45	1	3	10	1	1	3	4	0	1
2	43	2	3	7	1	1	3	4	0	1
3	42	3	2	9	1	1	3	3	0	1
4	36	3	3	8	1	1	3	2	0	1

```
Missing values:
wife_age      0
wife_edu      0
husband_edu   0
children      0
wife_religion 0
wife_working  0
husband_occ   0
living_index  0
media_exposure 0
target        0
dtype: int64
```


4. 주요 결과물 – 데이터 분석

데이터 수집 및 전처리

Feature Name	Type
 Contraceptive_method_used (target)	nominal
 Wifes_age	numeric
 Wifes_education	nominal
 Husbands_education	nominal
 Number_of_children_ever_born	numeric
 Wifes_religion	nominal
 Wifes_now_working%3F	nominal
 Husbands_occupation	nominal
 Standard-of-living_Index	nominal
 Media_exposure	nominal

- nominal

숫자로 저장되어 있지만, 연속형 수치로 해석x

- 딥러닝 모델이 필요한 정보

질문	이유
이 값이 연속적인가?	정규화 대상인가
순서 정보가 있는가?	embedding이 의미 있는가
단순한 구분만 필요한가?	one-hot이면 충분한가

4. 주요 결과물 – 데이터 분석

데이터 수집 및 전처리

Feature Name	Type
Contraceptive_method_used (target)	nominal
Wifes_age	numeric
Wifes_education	nominal
Husbands_education	nominal
Number_of_children_ever_born	numeric
Wifes_religion	nominal
Wifes_now_working%3F	nominal
Husbands_occupation	nominal
Standard-of-living_Index	nominal
Media_exposure	nominal

• 의미 기반 재분류

분류 기준 = 의미 + 모델 학습 관점

(1) 수치형(Numeric)

값의 차이와 크기 자체가 의미가 있음

- wife_age (16 ↔ 49)
- children (0 ↔ 16)

- ✓ 값 차이가 곧 정보
- ✓ 정규화 필요

(2) 순서형 범주(Ordinal)

값의 순서는 의미, 차이는 절대값 아님

- wife_edu (1 < 2 < 3 < 4)
- husband_edu
- living_index

- ✓ “높다/낮다”의 방향성 존재
- ✓ embedding / ordinal 처리 적합

(3) 명목형 범주(Nominal – 진짜 의미)

순서가 전혀 없음

- husband_occ (직업군)
- ✓ 1,2,3,4에 크기 의미 ✗
- ✓ 범주 구분만 필요

(4) 이진형(Binary)

참/거짓, 있음/없음

- wife_religion
- wife_working
- media_exposure

- ✓ 0/1 그대로 사용 가능

4. 주요 결과물 – 데이터 학습 및 모델정의

모델정의 및 컴파일

정형(Tabular) 모델 정의

- ☑ 데이터 분할 : 전체 데이터를 학습용/검증용/테스트용으로 분할하고, 클래스 비율이 유지되도록 **Stratified Split** 적용
- ☑ 전처리 구성 : 수치형 변수(wife_age, children)는 **Normalization** 적용, 범주형 변수는 **IntegerLookup**으로 인덱스화
- ☑ Embedding + MLP 모델 구조(Model B) : 범주형 변수는 ****Embedding(차원=2)****로 표현한 뒤 수치형 특징과 **Concatenate**하여, **Dense(128)–Dropout–Dense(64)–Dropout** 구조로 학습
- ☑ 모델 컴파일 : Adam 옵티마이저와 정수 레이블 기반 다중분류 손실 함수(**SparseCategoricalCrossentropy**)를 사용하고, **Accuracy**로 성능을 평가

Model: "B_embedding_mlp"

Layer (type)	Output Shape	Param #	Connected to
wife_age (InputLayer)	(None)	0	-
children (InputLayer)	(None)	0	-
cast_to_float (CastToFloat)	(None)	0	wife_age[0][0]
cast_to_float_1 (CastToFloat)	(None)	0	children[0][0]
wife_edu (InputLayer)	(None)	0	-
husband_edu (InputLayer)	(None)	0	-
wife_religion (InputLayer)	(None)	0	-
wife_working (InputLayer)	(None)	0	-
husband_occ (InputLayer)	(None)	0	-
living_index (InputLayer)	(None)	0	-
media_exposure (InputLayer)	(None)	0	-

4. 주요 결과물 – 데이터 학습 및 모델정의

모델정의 및 컴파일

```
from src.models import build_preprocessors, model_b_embedding_mlp
from src.data_io import FEATURES, NUMERIC_COLS, CATEGORICAL_COLS

norm_layers, lookup_layers = build_preprocessors(train_ds, NUMERIC_COLS, CATEGORICAL_COLS)

# (2) 모델 생성 (예: Model B - Embedding MLP)
model = model_b_embedding_mlp(
    feature_cols=FEATURES,
    numeric_cols=NUMERIC_COLS,
    categorical_cols=CATEGORICAL_COLS,
    norm_layers=norm_layers,
    lookup_layers=lookup_layers,
    num_classes=3,
    dropout=0.3,
    l2=1e-4
)

# (3) 모델 요약 출력 (PPT용 캡처 대상)
model.summary()
```

Model: "B_embedding_mlp"

Layer (type)	Output Shape	Param #	Connected to
wife_age (InputLayer)	(None)	0	-
children (InputLayer)	(None)	0	-
cast_to_float (CastToFloat)	(None)	0	wife_age[0][0]
cast_to_float_1 (CastToFloat)	(None)	0	children[0][0]
wife_edu (InputLayer)	(None)	0	-
husband_edu (InputLayer)	(None)	0	-
wife_religion (InputLayer)	(None)	0	-
wife_working (InputLayer)	(None)	0	-
husband_occ (InputLayer)	(None)	0	-
living_index (InputLayer)	(None)	0	-
media_exposure (InputLayer)	(None)	0	-

4. 주요 결과물 – 데이터 학습 및 모델정의

모델정의 및 컴파일

정형(Tabular) 모델 정의

- ☑ 데이터 분할 : 전체 데이터를 학습용/검증용/테스트용으로 분할하고, 클래스 비율이 유지되도록 Stratified Split 적용
- ☑ 전처리 구성 : 수치형 변수(wife_age, children)는 Normalization 적용, 범주형 변수는 IntegerLookup으로 인덱스화
- ☑ Embedding + MLP 모델 구조(Model B) : 범주형 변수는 **Embedding(차원=2)**로 표현한 뒤 수치형 특징과 Concatenate하여, Dense(128)–Dropout–Dense(64)–Dropout 구조로 학습
- ☑ 모델 컴파일 : Adam 옵티마이저와 정수 레이블 기반 다중분류 손실 함수(SparseCategoricalCrossentropy)를 사용하고, Accuracy로 성능을 평가

emb_wife_religion (Embedding)	(None, 2)	6	lookup_wife_reli...
emb_wife_working (Embedding)	(None, 2)	6	lookup_wife_work...
emb_husband_occ (Embedding)	(None, 2)	10	lookup_husband_o...
emb_living_index (Embedding)	(None, 2)	10	lookup_living_in...
emb_media_exposure (Embedding)	(None, 2)	6	lookup_media_exp...
concatenate (Concatenate)	(None, 16)	0	reshape[0][0], reshape_1[0][0], emb_wife_edu[0][...], emb_husband_edu[...], emb_wife_religio..., emb_wife_working..., emb_husband_occ[...], emb_living_index..., emb_media_exposu...
dense (Dense)	(None, 128)	2,176	concatenate[0][0]
dropout (Dropout)	(None, 128)	0	dense[0][0]
dense_1 (Dense)	(None, 64)	8,256	dropout[0][0]
dropout_1 (Dropout)	(None, 64)	0	dense_1[0][0]
dense_2 (Dense)	(None, 3)	195	dropout_1[0][0]
Total params: 10,691 (41.77 KB)			

4. 주요 결과물 – 데이터 학습 및 모델정의

모델생성 및 테스트

🔗 생성한 모델을 로드 후 테스트하기

```
# X_test에서 한 행 선택 (0번째)
row = X_test.iloc[[0]].copy()
y_true = int(y_test.iloc[0]) if hasattr(y_test, "iloc") else int(y_test[0])

# Keras Functional 입력(dict)으로 변환
x_one = {col: row[col].values for col in row.columns}

proba = loaded_model.predict(x_one, verbose=0)[0]
y_pred = int(np.argmax(proba))

class_names = ["미사용", "단기 피임", "장기 피임"]

print("정답:", class_names[y_true], f"(class={y_true})")
print("예측:", class_names[y_pred], f"(class={y_pred})")

prob_df = pd.DataFrame({
    "클래스": class_names,
    "확률(%)": np.round(proba * 100, 2)
}).sort_values("확률(%)", ascending=False)

prob_df
```

정답: 단기 피임 (class=1)
예측: 미사용 (class=0)

	클래스	확률(%)
0	미사용	42.599998
2	장기 피임	40.520000
1	단기 피임	16.879999

4. 주요 결과물 – 데이터 학습 및 모델정의

모델학습 및 시각화

○ 학습과정 시각화

☑ 정확도(Accuracy)

-Training Accuracy

전반적으로 완만하게 상승하며 학습이 안정적으로 진행됨

-Validation Accuracy


학습 초반부터 훈련 정확도보다 더 높은 수준을 유지하며, 후반부로 갈수록 지속적인 상승 추세

☑ 손실(loss)

Training Loss / Validation Loss 모두 지속적으로 감소

Validation Loss가 Training Loss보다 낮거나 유사한 수준을 유지

후반부에도 손실이 다시 증가하지 않음



4. 주요 결과물 – 데이터 학습 및 모델정의

모델 성능 비교 및 선정

모델 성능 비교 및 최종 모델 선정

- ☑ Model A/B/C를 동일 데이터로 학습 후 Accuracy, Macro-F1, Weighted-F1 지표로 성능을 비교
- ☑ 그 결과 Macro-F1이 가장 높은 Model C (0.377)를 최종 모델로 선정
- ☑ Macro-F1은 클래스별 성능을 동일 가중치로 반영하므로, 특정 클래스에 치우친 정확도(Accuracy)보다 균형 잡힌 분류 성능

	Model	Accuracy	Macro-F1	Weighted-F1
0	C	0.457014	0.376751	0.420510
1	A	0.493213	0.340017	0.405732
2	B	0.488688	0.338340	0.401630

```
rows = []
for k, pack in evals.items():
    y_true = pack["y_true"]

    # y_pred가 있으면 그대로 사용
    if "y_pred" in pack:
        y_pred = pack["y_pred"]
    else:
        # 없으면 y_prob로 argmax에서 y_pred 생성
        y_pred = pack["y_prob"].argmax(axis=1)

    macro_f1 = f1_score(y_true, y_pred, average="macro")
    weighted_f1 = f1_score(y_true, y_pred, average="weighted")
    acc = accuracy_score(y_true, y_pred)

    rows.append({
        "Model": k,
        "Accuracy": acc,
        "Macro-F1": macro_f1,
        "Weighted-F1": weighted_f1,
    })

compare_df = pd.DataFrame(rows).sort_values("Macro-F1", ascending=False).reset_index(drop=True)
display(compare_df)

best_key = compare_df.loc[0, "Model"]
print("Best model by Macro-F1 =", best_key)
```

Best model by Macro-F1 = C

4. 주요 결과물 – 데이터 학습 및 모델정의

모델 성능 비교 및 선정

Optimization 시도

- ☑ Optimization 시도: (lr / dropout / batch 조합 3개) → Macro-F1 개선 실패(소폭 하락)
- ☑ 해석: 데이터가 작고(1,473행), 클래스 불균형/겹침이 있어 단발 split에서 변동성이 큼, 제한된 탐색(3조합)으로는 개선이 보장되지 않음
- ☑ 다음 개선안(후속): 더 넓은 탐색 / 스케줄러 등

```
model.compile(
    optimizer=tf.keras.optimizers.Adam(learning_rate=hp["learning_rate"]),
    loss=tf.keras.losses.SparseCategoricalCrossentropy(),
    metrics=[tf.keras.metrics.SparseCategoricalAccuracy(name="acc")]
)

cb = [tf.keras.callbacks.EarlyStopping(monitor="val_loss", patience=1, restore_best_weights=True)]

t0 = time.perf_counter()
model.fit(train_ds, validation_data=val_ds, epochs=15, verbose=0, callbacks=cb)
t1 = time.perf_counter()

macro_f1, val_loss, val_acc = eval_val_macro_f1_and_loss(model, val_ds)

tuning_rows.append([
    "rank": i,
    "learning_rate": hp["learning_rate"],
    "batch_size": hp["batch_size"],
    "dropout": hp["dropout"],
    "val_macro_f1": macro_f1,
    "val_loss": val_loss,
    "val_acc": val_acc,
    "train_time_sec": round(t1 - t0, 2)
])

opt_df = pd.DataFrame(tuning_rows).sort_values("val_macro_f1", ascending=False).reset_index(drop=True)
display(opt_df)
```

	rank	learning_rate	batch_size	dropout	val_macro_f1	val_loss	val_acc	train_time_sec
0	2	0.000100	64	0.2	0.340738	1.005541	0.493213	3.21
1	3	0.000050	128	0.3	0.254733	1.050310	0.447964	3.36
2	1	0.000075	64	0.3	0.248898	1.029172	0.434389	3.43

4. 주요 결과물 – 데이터 학습 및 모델정의

분류보고서 및 혼동행렬

클래스별 성능

☑ 미사용


‘미사용’ 클래스는 비교적 높은 정분류 비율을 보이며 다른 클래스 대비 안정적인 예측 성능을 나타냈다.

☑ 단기

‘단기’ 클래스는 일부 정확한 예측을 수행하였으나, ‘미사용’ 및 ‘장기’ 클래스와 혼동되는 경향을 보였다.

☑ 장기

‘장기’ 클래스는 재현율이 낮아, 실제 장기 피임임에도 불구하고 ‘미사용’ 또는 ‘단기’로 오분류되는 경우가 다수 발생하였다.



4. 주요 결과물 – 데이터 학습 및 모델정의

모델 예측

입력 정보에 입력 후 예측 결과 확인

원구동계 및 사회경제적 정보를 입력하면 피임 방법(피임 방법, 피임 방법, 피임 방법)을 확률로 예측합니다.

모델 선택

사용할 모델 선택

model_b_embedding_mlp.keras

입력 정보

아내의 나이

28

아내의 종교 (0=이슬람 외, 1=이슬람)

1

아내의 교육 수준

2-중하

아내의 현재 경제활동 여부 (0=예, 1=아니오)

0

교육 수준 코드: 1=초등(저학력), 2=중하, 3=중상, 4=고졸(고학력)

남편의 직업 유형

2-농업 종사자

주제어(다섯은 1-4의 시열을 원주순만 제공되며, 최종과 대를 거쳐 현재 정보는 포함되어 있지 않습니다.)

직업 유형 코드: 1=무직, 2=농업, 3=농림자, 4=비농림자

남편의 교육 수준 (1=초등 ~ 4=고졸)

2

생활수용 지수 (1=낮음 ~ 4=높음)

2

출산한 자녀 수

2

미디어 접근성 (0=원초, 1=높음)

0

예측 실행

예측 결과: 피임 방법 미사용

피임 방법별 선택확률

	피임 방법	선택확률(%)
0	피임 방법 미사용	44.3
1	장기 피임 방법	14.6
2	단기 피임 방법	41.1

운영 임계값(보류 전략) 시연

최대 선택확률이 임계값보다 낮으면 결과를 확정하지 않고 보류합니다.

확신 임계값 τ (최대 확률 $< \tau$ 이면 보류)

0.45

예측 신뢰도 부족으로 결과 보류 (최대 확률 = 0.443 < 임계값 0.45)

6. 소감 및 후기

프로젝트 성과

변수 유형 구분(수치형/범주형), 정규화 및 임베딩 적용 등 데이터 전처리 과정의 중요성을 실무 관점에서 이해할 수 있었으며,
단순 모델 구현을 넘어 모델 비교 및 성능 지표 기반 최종 모델 선정 경험을 쌓을 수 있었다.

아쉬웠던 점

공개 데이터셋을 활용하였으나,
데이터 수집 과정에서 변수의 한계와 클래스 간 특성 중첩 문제가 존재하였다.
또한 시간적 제약으로 인해 추가적인 외부 데이터 결합이나
고급 특성 엔지니어링을 충분히 적용하지 못한 점이 아쉬움으로 남는다.